

TIMING-ROOT-CAUSE — onde nasce o erro temporal

Investigação empírica, sem nenhuma alteração de código/commit/config. Arquivo: videos/videofull.mkv (297.283.589 bytes, mtime 2026-09-18, duração 88.576 s). Modelo: models/ggml-medium.bin. Sem cache em nenhum passo (whisper-cli direto + extração WAV fresca). Data: 2026-09-19.

1. Fala real no áudio (evidência independente, sem Whisper)

Método: silencedetect + envelope RMS em passos de 0.1 s, áudio integral.

- Silêncio de 3.13 s em 51.14 → 54.27.
- Subida abrupta de energia em 54.2 → 54.3 (rms 0.015 → 0.062).
- Rajada de fala até ~58.4; silêncio a partir de ~58.5 (rms < 0.01).

fala real: START ≈ 54.3s, END ≈ 58.4s (margem ±0.15s, bordas por energia)
duração ≈ 4.1s – compatível com a frase de ~15 palavras em ritmo de gameplay

2. JSON RAW do Whisper (pipeline atual, sem VAD, sem cache)

Comando direto, mesmo WAV que o pipeline extrairia (chunk 30–60, 16 kHz mono):

```
whisper-cli -m models/ggml-medium.bin -f chunk30.wav -ojf -l auto/pt -nt
```

Resultado (idêntico com -l auto e -l pt): 1 segmento local [0.00→30.00], 18 tokens — alucinação repetitiva, com p alto nos tokens alucinados:

```
' e' 0.00→0.42 p=0.09 | ' ó' 0.42→0.84 p=0.06 | 'leo' 0.84→2.09 p=0.67
' de' 2.09→2.94 | ' céu' 2.96→4.20 p=0.93 | ' por' 4.20→5.46
' toda' 5.46→7.15 p=0.99 | ' a' 7.15→7.57 | ' plataforma' 7.57→11.79 p=0.99
... "toda a plataforma" em loop até 24.45 (p até 1.00) ...
' você' 24.45→26.06 p=0.20 | '...' 26.09→29.99 p=0.18 | [_EOT_] 30.00
texto: "e óleo de céu por toda a plataforma toda a plataforma..."
```

A frase real ("Agora eu vou matar..."), audível em local 24.3→28.4 do chunk (WAV conferido: rms 0.055 nesse trecho), não foi reconhecida. Confiança alta (até 1.00) em palavra alucinada: p não discrimina alucinação.

Pipeline atual completo (transcribe_vulkan, sem VAD) em videofull.mkv:

```
SEG [0.00->30.00] "      ..." (alucinação)
SEG [30.00->60.00] "e óleo de céu..." (alucinação; frase ausente)
SEG [60.00->90.00] "Ver se não vai dar bom..." (correto – mesmo texto da era VAD)
```

3. Tabela fundamental

Fonte	Início	Fim
--- --- ---		
Áudio real	54.30	58.40
Whisper RAW (era VAD, work/videofull)	30.00	47.80 (words; +7 degenerados em 47.80)
Whisper RAW (atual, sem VAD)	—	— (frase ausente; loop "plataforma")
Word após parse	= RAW + 30 (soma exata, verificada)	idem
Transcript global	= parse (cópia, sem retoque)	idem
Cue	= start da 1ª word (código verificado)	= end última word (+piso 1 s)
SRT / ASS	= cue – clip_start (subtração exata)	idem

Áudio real	54.30	58.40
Vídeo final	= SRT (trim+setpts 0-based)	idem

Primeira etapa com valor diferente do real: o próprio Whisper (etapa 1). Nenhuma etapa posterior reescreve `Word.start/end` (verificado função a função na auditoria anterior e reconferido neste HEAD).

4. Segmento vs words (o ponto da §4 do procedimento)

Era VAD: segmento 30.0→58.61, words 30.0→47.80 + pilha degenerada. O Clipper usa `segment.start/end` só para janelas candidatas e `word.start/end` para captions (código verificado). Respostas:

- segment 30 → 58 + words 55 → 59 → legenda começa em 55 (da word).
- segment 30 → 58 + words em 30 → problema nasceu no Whisper.
- Nosso caso era o segundo: words em 30–47.8 (Caso 4, §6 do procedimento —

words erradas, não deslocamento constante; 17.8 s de words vs 4.1 s reais exclui offset). Nota: o `segment.end` 58.61 coincide com o fim real (58.4), mas é fronteira de decodificação, não medição da fala.

5. Linha 45–65 s (Caso 4 confirmado para a era VAD)

45.0 ————— 65.0
 áudio real: [silêncio 51.1-54.3][FALA 54.3-58.4][silêncio]
 VAD-era words: [30.0→47.8 + pilha DEG em 47.8]
 VAD-era segment: [30.0→58.61]
 atual sem VAD: [ausente – alucinação "plataforma"]

6. Cache e proveniência (§8)

Nenhum cache do Clipper foi usado nesta investigação (CLI direto). O `work/videofull/transcription/transcript.raw.json` é artefato antigo da era VAD (status draft→approved pelo usuário) e foi usado só como objeto de estudo, não como evidência do comportamento atual.

VEREDITO

O timestamp já está errado no RAW do Whisper.

Com o qualificador honesto de duas eras: na era VAD, words certas no tempo errado (30–47.8 vs 54.3–58.4, timeline comprimida — mecanismo em código); hoje, sem VAD, a frase some numa alucinação repetitiva de chunk ruidoso. Nos dois casos, a primeira divergência está na medição do modelo.

PRIMEIRA DIVERGÊNCIA

Etapa: Whisper (alinhamento por token no chunk 30–60)
 Valor correto: 54.30 → 58.40 (energia acústica, ±0.15s)
 Valor observado (era VAD): 30.00 → 47.80 (+degenerados)
 Valor observado (atual): frase ausente
 Diferença: ~24 s (era VAD) / perda total (atual)
 Evidência: `silencedetect` + RMS + `whisper-cli` direto, sem cache

TIMELINE

ÁUDIO REAL 54.3 → 58.4 ████████
 WHISPER RAW 30.0 → 47.8 (VAD) ou ausente (atual)
 WORD = RAW + offset (parse exato)
 TRANSCRIPT = WORD (cópia)
 CUE = 1ª word → última word (sem reescrita)
 SRT = CUE - `clip_start` (conversão única, exata)
 VÍDEO = SRT (trim+setpts, zero casado)

CONFIANÇA: ALTA

- Fala real em 54.3–58.4: dois métodos independentes concordam (silêncio de 3.1 s antes + subida 4× de energia + decaimento simétrico).
- Parse/pipeline inocentes: cada transformação reconferida no HEAD atual.
- Ressalva explícita: a alucinação atual foi medida em 1 run por configuração de idioma (2 runs totais, mesmo resultado); decodificação greedy é determinística, mas binary/modelo podem diferir dos que geraram o raw.json antigo — por isso a era VAD e a atual são reportadas separadamente.